

基于前向滚动 EMD 技术的预测模型^①

张承钊¹, 潘和平^{2,3}

(1. 电子科技大学 经济与管理学院, 成都 611731; 2. 重庆金融学院, 重庆 400067; 3. 四川大学 经济学院, 成都 610064)

摘要:运用经验模态分解(EMD)、人工神经网络(ANN)和时间序列, 基于分解—重构—集成的思想, 构建了一个组合预测模型。在模型的构建过程中, 提出了对股票指数序列进行逐日前向滚动 EMD 分解的思路, 将分解后的本征模函数(IMF)分量输入神经网络进行组合预测。运用上述基于前向滚动 EMD 模型分析沪深 300 指数和澳大利亚指数的波动特点和走势。结果显示: 前向滚动 EMD 模型比 ARIMA 模型、GARCH 模型和 BP 神经网络模型具有更高的预测精度。

关键词:经验模态分解; 人工神经网络; 前向滚动分解; 本征模函数

中图分类号:F832.5 **文献标志码:**A **文章编号:**1002-980X(2015)05-0070-08

1 文献综述

股票市场的变化与整个经济的发展密切相关, 股票市场在市场经济中始终发挥着经济状况晴雨表的作用。正确分析股票价格波动的特点和规律, 进而有效预测其走势, 对于国家制定经济政策、企业制定生产经营决策具有重要的现实意义。个人投资者、股票基金经理和财务分析师试图用其专业知识并借助股票分析工具预测股票价格。由于更高的准确性意味着能获得更多的利润, 因此他们努力寻找更好的方法来准确预测股票价格。

股票价格预测方法大体分为线性模型方法、非线性模型方法和组合模型方法。线性模型主要包括 ARMA 模型、ARIMA 模型和线性回归模型等; 非线性模型方法主要包括人工神经网络(artificial neural network, ANN)、支持向量机(support vector machine, SVM)、经验模态分解(empirical mode decomposition, EMD)等; 组合模型方法就是将上述线性模型与非线性模型的单模型按照一定规则相组合的方法。

不同学者对股票市场的复杂波动性展开了研究。在过去的几十年里, 传统的统计和计量经济学技术(如线性回归、协整分析、GARCH 模型族、随机游走模型、向量回归和误差修正模型)被广泛应用于金融市场价格预测。例如, De Gooijer、Ray 和 Krager^[1]在 20 世纪 80 年代使用时间序列多元自适应回归样条函数来估计和预测 4 种主要货币的周汇

率。Awartani 和 Corradi^[2]调查了不同 GARCH 族模型的样本预测能力的相对输出, 特别强调了非对称序列的预测内容。一些学者认为, 大多数金融时间序列(如股票、外汇和原油等)表现出显著的复杂行为, 具有很强的非线性和非平稳性^[3-5]。Cotfas^[6]用有限维希尔伯特空间的傅里叶变换来预测股票回报的变化趋势。然而, 傅里叶变换假设处理的信号是线性的和平稳的。In 和 Kim^[7]使用小波分析方法考察了不同时期澳大利亚证券市场与期货市场的关系。小波分析的特点表现为其非自适应特性。希尔伯特—黄变换(Hilbert-Huang transform, HHT)被广泛用于金融时间序列(如原油^[8-9]、外汇^[10]和股票市场^[11])的预测。Yu、Wang 和 Lai^[8]提出了一种基于 EMD 的神经网络集成学习范式, 用于预测世界原油现货价格, 并用两个主要的原油现货价格——西德克萨斯轻质原油(west Texas intermediate, WTI)现货价格和布伦特(Brent)原油现货价格——的时间序列验证这种基于 EMD 的神经网络集成学习范式的有效性。Zhang、Yu 和 Wang 等^[9]使用一个基于 EMD 的事件分析方法更好地估计突发事件对原油价格波动的影响。Lin、Chiu 和 Lin^[10]提出了一种基于 EMD 和最小二乘支持向量回归(least square support vector regression, LSSVR)的混合预测模型来预测汇率。Cheng 和 Wei^[11]提出了一个基于 EMD 的混合时间序列支持向量回归(support vector regression, SVR)模型, 用于预测中国台湾证券交易所加权指数的股票价格。Li 和 Bao^[12]

收稿日期: 2015-02-18

作者简介: 张承钊(1975—), 男, 四川成都人, 电子科技大学经济与管理学院博士研究生, 研究方向: 金融工程、金融投资;
潘和平(1961—), 男, 陕西西安人, 重庆金融学院副院长、教授, 博士生导师, 研究方向: 金融工程、智能金融。

① 中国智能金融研究院“融市场预测模型项目”(2014-2016)。

使用 EMD 方法预测了 5 大世界市场。Ivanov、Jones 和 Zaima^[13]检验了交易型开放式指数基金、道琼斯工业指数期货市场、标准普尔 500 指数、标准普尔 400 指数、纳斯达克 100 指数和罗素 2000 指数的价格发现时间行为,发现现货市场而非期货市场导致价格发现。Mensi、Beljid 和 Boubaker 等^[14]采用 VAR-GARCH 模型调查了 2000—2011 年期间标准普尔 500 指数以及能源、食品、黄金和饮料等大宗商品价格指数的收益率相关性和波动率传导性,发现标准普尔 500 指数过去的冲击和波动强烈影响石油和黄金市场。Caraianni^[15]通过复杂网络调查了欧洲主要新兴股票市场收益率的特征,将每日收益率序列转变为复杂网络并分析这些网络的局部属性(如度分布、聚类、或平均线长度)。Wu^[16]调查了从 1986 年 2 月 1 日到 1996 年 12 月 31 日美元兑德国马克与美元兑日元的汇率相关性,实证结果显示两种汇率在 1986—1989 年的相关性高于在 1990—1993 年的相关性。

国内学者熊志斌^[17]建立了 ARIMA 融合神经网络的时间序列预测模型,对 3 种人民币汇率序列的仿真实验结果表明,组合模型的预测准确率显著高于包括随机游走模型在内的单一模型的预测准确率。黄海南和钟伟^[18]运用 GARCH 类模型对上证指数收益率进行了全面估计及样本外预测,通过 M-Z 回归和利用损失函数评价 GARCH 类模型的波动率预测表现。李成刚、田益祥和何继锐^[19]引入 EMD 方法,将含有多个震荡模式的数据分解为满足一定条件的多个单一震荡模式分量的线性叠加,对震荡模式分量应用非参数的 AC(analog complexing)算法,根据历史上相似时期的已知延拓进行预测,利用 GMDH(group method of data handling)客观确定权重、构建组合预测模型,运用该模型并结合原油期货数据进行实证。杨云飞、鲍玉昆和胡忠义等^[20]提出了一种基于 EMD 和 SVM 的非线性组合预测方法,用于检验 WTI 原油现货价格和 Brent 原油现货价格,结果表明该方法比单一的 SVM 模型和人工神经网络模型具有较高的预测精度。

从以上研究文献可看出,虽然各种智能算法模型在不同的条件下具有较高的预测精度,但是目前的主流趋势是利用各单一智能算法模型的优点构建组合预测模型来实现更好的预测性能。Krogh 和 Vedelsby^[21]证明了如下思想:当构成组合预测模型的单模型足够精确且足够多样化时,组合预测模型一定能获得比单模型更好的效果。当前智能算法的发展趋势正是发展各种算法的混合方法,因为任何一种典型方法不能在所有场合都优于其他方法。虽

然国内外学者普遍采用 EMD 方法研究股票市场、外汇市场和原油,但是他们大多采用几年的窗口采集数据进行 EMD 分解。然而,股市预测的实时性要求很高,长达几年的窗口采集数据会造成时延,从而影响股市预测效果。本文提出一种前向滚动的滑动窗口 EMD 技术,将分解后的 IMF 序列输入神经网络训练并得到预测结果,基于分解—重构—集成的思想构建一个多尺度组合预测模型,在该模型的基本框架下分析沪深 300 指数和澳大利亚指数的波动情况及其走势。

2 模型构建与分析

本文将前向滚动 EMD 技术与神经网络技术相结合,首先利用前向滚动 EMD 技术将原始时间序列分解为不同频率的子序列,然后利用神经网络技术针对每个子序列分别建立预测模型,最后将各子序列的预测结果进行叠加,得到模型的最终预测结果。研究中主要涉及 EMD 技术、前向滚动分解技术和神经网络技术。

2.1 EMD 技术

EMD 技术由我国台湾学者黄锬等^[22]提出,是一种非线性信号变换技术。它是 HHT 的基本组成部分,使用三次样条插值算法。HHT 是 EMD 和 Hilbert 频谱分析的组合。EMD 算法的关键是三次样条插值——它消耗了最多的计算量。EMD 算法涉及大量筛选过程的计算,采用过长窗口截取数据和收集数据会导致不可忽视的时延。而股票预测的实时性要求很高,很长的时延是不可接受的。鉴于此,本文提出了一个基于滑动窗口的三次样条插值算法,将前向滚动 EMD 技术与人工神经网络技术相结合来预测金融市场,以期获得比单一模型更高的预测精度。

EMD 算法将复杂的数据集分解为有限的组成分量,这些组成分量被称为本征模函数(intrinsic mode function, IMF)。一个 IMF 通常代表一种简单的振荡模式对应的简谐函数。根据定义,一个 IMF 具有如下两个特征:第一,在整个数据集中极值数量与过零点数量必须相同或最多相差 1 个;第二,局部极大值的包络和局部极小值的包络的平均值在任意一点为 0。给定一个信号 $x(t)$, EMD 筛选过程的步骤如下:①确定 $x(t)$ 的局部极大值和局部极小值;②利用三次样条插值算法分别确定由所有极大值形成的上包络 $U(t)$ 和由所有极小值形成的下包络 $L(t)$;③计算两个包络的平均值 $m(t)$, $m(t) = [U(t) + L(t)]/2$;④从信号 $x(t)$ 中减去平均值 $m(t)$, 得到一个 IMF 的候选值,即 $c(t) = x(t) - m$

(t); ⑤检查 $c(t)$ 是否满足 IMF 的两个特征, 若满足, 则可认定 $c(t)$ 为从原始信号 $x(t)$ 中筛选出的一个 IMF, 若不满足, 则重复步骤 ①~④, 直到 $c(t)$ 最终满足 IMF 的两个特征; ⑥将原始信号 $x(t)$ 减去 IMF 分量 $c(t)$, 得到残差 $r(t)$, 即 $r(t) = x(t) - c(t)$, 并继续对 $r(t)$ 进行分解; ⑦将 $r(t)$ 作为输入数据并重复步骤 ①~⑥, 得到满足两个特征的 IMF 序

列。

经过上述 EMD 筛选过程, 信号被表示为从高频部分到低频部分的 IMF 序列与残差的和, 即

$$x(t) = r(t) + \sum_{i=1}^n c_i(t). \quad (1)$$

式(1)中, n 是 IMF 组成分量的数目。图 1 描述了 EMD 筛选过程。

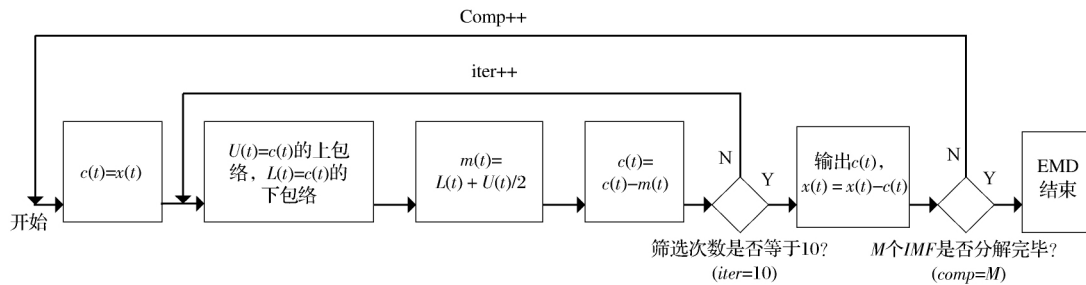


图 1 EMD 筛选过程

终止分解 IMF 序列有一些条件, 这些条件导致数据分解对本地扰动和增加新数据很敏感。为了解决这一问题, Wu 和 Huang^[23] 提议固定分解数据的筛选次数, 通过将筛选的最大次数固定为 10 来保证分解数据的稳定性和收敛性。

由图 1 可知, EMD 筛选过程包括两个循环——组件循环和迭代循环。EMD 算法有两个参数: 截取信号的窗口长度 W ; IMF 的个数 M 。在实践中, 根据不同的应用和需要来设置这些参数, 如分析股票市场的时间序列分解得到的 IMF 个数通常为 5~10。

2.2 前向滚动分解技术

一般来说, EMD 处理信号时使用一个窗宽很长的窗口 W , 它确保有足够的极值计算三次样条插值并产生相应的 IMF 序列。然而, 在数据收集时使用的窗口窗宽过长会导致长时延。EMD 算法处理需要 HHT 算法来实现。当提供新数据时, 要确保 EMD 分解数据准确、可靠。

然而, 三次样条插值的边界条件假设使得包络的边界间隔可能有误。由于 EMD 算法对数据有依赖性, 这些错误会在 IMF 序列之间传播并影响 IMF 序列的准确性, 因此必须确定窗口插入值是可靠的, 如此才能谨慎地解释结果。可通过部分重叠的滑动窗口截取数据, 并将截取的数据用于 EMD。图 2 是通过滑动窗口实时插值的示意图。当新数据可用时, 立即产生可靠的窗口参数来实现实时的 EMD。减小窗口宽度 W 是非常重要的, 这会使延迟降低。

2.3 人工神经网络

下面阐述神经网络的原理。利用神经网络方法




图 2 通过滑+动窗口实时插值的示意图

预测股票市场指数, 首先需要定义一个从 n 维输入空间 $\{x(x_1, x_2, \dots, x_n)\}$ 到 m 维输出空间 $\{z(z_1, z_2, \dots, z_m)\}$ 的映射 M :

$$M: x(x_1, x_2, \dots, x_n) \rightarrow z(z_1, z_2, \dots, z_m). \quad (2)$$

假定已定义了在当前时间 t 的 n 元特性可用数据集 $DX(t)$ 和 $DY(t)$, 要预测未来一个或多个目标指数的 m 个实际值对应的预测值。使用神经网络预测股指时需要合理确定神经网络的两个架构参数——隐藏神经元个数和滞后阶数。假设股票指数预测问题可建模为一个非线性连续函数映射, 应使用具有一个非线性隐藏层的三层感知器神经网络——这是模型的基本架构。然而, 一般来说, 这种映射应被认为是可能含有不连续函数的任何函数, 所以神经网络的一般架构应是一个含有两个非线性隐藏层的四层感知器。在这两种情况下, 输出层应是线性的, 因为输出值可以是正的或负的实数值。

三层感知器神经网络有一个非线性隐藏层, 隐藏层有 h 个隐藏神经元。三层感知器神经网络可表示如下:

$$z_j = \sum_{k=1}^h w_{kj} y_k + b_j \quad (j = 1, 2, \dots, m); \quad (3)$$

$$y_k = \varphi\left(\sum_{i=1}^n w_{ik} x_i + a_k\right) \quad (k = 1, 2, \dots, h)。(4)$$

这里 y_k 是第 k 个隐藏神经元的输出; a_k 、 b_j 分别是第 k 个隐藏神经元和第 j 个输出神经元的偏移量; $\varphi(\cdot)$ 是隐藏神经元的非线性转移函数, 通常采用双曲函数形式, 如式(5)所示。

$$\varphi(x) = \frac{1}{1 + e^{-x}}。(5)$$

对于有两个非线性隐藏层的四层感知器神经网络, 每个隐藏层的转移函数都有类似于式(4)的函数相对应。但是, 两个隐藏层可以含有不同数目的隐藏层神经元。本文采用三层感知器神经网络。

3 历史数据和统计特征

正确预测股票市场可为国家宏观调控提供重要的参考依据, 可为股民提供投资依据。股票价格受众多因素(如经济基本面、行业因素、政治、投资者心理等)的影响, 各因素的影响程度和影响持续时间各有差异, 利用传统的时间序列分析方法不能完全捕获其变化特征。本文采用前向滚动 EMD 分解技术, 将原始股票指数序列分解为多个 IMF 子序列, 每个子序列与原始信号相比特征单一, 从而有利于预测模型更好地捕获、模拟其特征规律, 取得良好的

预测效果。

3.1 数据集

本文将检测两个亚太股票指数——澳大利亚指数和沪深 300 指数。沪深 300 指数由中国上海和深圳证券交易所于 2005 年 4 月 8 日联合发布, 反映了中国沪深股市的大致运行状况, 是中国的基准股票指数。在世界股票市场生态系统中, 美国股票市场为第一世界, 其走势不受其他国家股市的影响。除美国之外的其他发达国家(如 G7 国际和澳大利亚)的股票市场属于第二世界, 受美国股票市场的影响较大, 具有更好的可预测性。正因如此, 澳大利亚指数具有更好的风险可控性和预测的经济价值。数据集的数据来源是锐思金融数据库(www.resnet.cn)。本文的实证数据集样本是 2009 年 4 月 21 日至 2014 年 3 月 26 日的澳大利亚指数和 2009 年 2 月 9 日至 2014 年 4 月 2 日的沪深 300 指数。数据集分为两个子集: 前 4 年的数据为训练集; 最近一年的数据为测试集。上述两个亚太股票指数的统计数据见表 1, 收盘价的日线图见图 3。样本的时间跨度覆盖了许多重要的经济事件, 因此笔者认为这一时间跨度对训练模型是足够的。

表 1 两个亚太股票指数收盘价的描述性统计结果

指数	统计项	样本点数	均值	标准差	最大值	最小值
澳大利亚指数	所有样本	1250	4645.499	393.2207	5477.000	3627.200
	训练集	1000	4512.312	326.3980	5160.000	3627.200
	测试集	250	5167.677	192.7998	5477.000	4633.500
沪深 300 指数	所有样本	1250	2755.341	413.5218	3787.030	2086.972
	训练集	1000	2861.166	398.1521	3787.030	2115.680
	测试集	250	2351.679	137.2191	2634.322	2086.972




图 3 两个亚太股票指数的收盘价

3.2 两个亚太股票指数的 IMF 分量

根据 EMD 算法的定义, 原始信号经 EMD 算法分解后得到的各 IMF 序列相互正交, 即线性无关。

然而, 正如黄锬等^[22]所述, 正交性取决于分解方法。EMD 算法是一个非线性的方法, 这保证了经 EMD 分解后的各 IMF 序列相互正交。图 4 和图 5 为两

个亚太股票指数的 IMF 分量和残差图。EMD 分解的 IMF 序列层数越多,细节信号和近似信号的平稳性就越好、预测值越精确。但是,分解过程本身存在计算误差,误差随着分解层数的增多而增大,这会降低预测精度。




图 4 澳大利亚指数收盘价的 IMF 分量图




图 5 沪深 300 指数收盘价的 IMF 分量图

4 预测模型的性能标准

在参考了 Lu、Lee 和 Chiu^[24] 以及 Tay 和 Cao^[25] 提出的一些性能指标后,本文使用如下性能标准评估预测效果:平均绝对百分比误差(mean absolute percentage error,MAPE);均方根误差(root-mean-square error, RMSE);平均绝对误差(mean absolute difference, MAD);命中率(directional

symmetry,DS);上升趋势命中率(correct uptrend, CP);下降趋势命中率(correct downtrend,CD)。表 2 列出了这些性能标准的计算公式。其中:MAPE、RMSE 和 MAD 是测度实际值与预测值的偏差的指标,可用于评估预测误差。其值越小,表明预测值越接近于实际值;DS 以百分比的形式给出了股票指数方向预测的正确率;CP 以百分比的形式给出了上升趋势时股票指数方向预测的正确率;CD 以百分比的形式给出了下降趋势时股票指数方向预测的正确率。可根据 DS、CP 和 CD 了解预测的准确性,因为在许多情况下我们并不需要知道未来的具体预测值,只需知道是涨还是跌即可。

表 2 预测模型的性能标准及其计算公式

性能标准	计算公式
MAPE	$MAPE=\frac{1}{n} \times \sum_{i=1}^n \left \frac{T_i-A_i}{T_i} \right \times 100\%$
RSME	$RSME=\sqrt{\frac{1}{n} \times \sum_{i=1}^n (T_i-A_i)^2}$
MAD	$MAD=\frac{1}{n} \times \sum_{i=1}^n T_i-A_i $
DS	$DS=\frac{100}{n} \sum_{u=1}^n d_i, d_i=\begin{cases} 1, & (T_i-T_{i-1})(A_i-A_{i-1}) \geq 0 \\ 0, & \text{其他} \end{cases}$
CP	$CP=\frac{100}{n_1} \sum_{u=1}^n d_i,$ $d_i=\begin{cases} 1, & (A_i-A_{i-1}) > 0 \text{ 且 } (T_i-T_{i-1})(A_i-A_{i-1}) \geq 0 \\ 0, & \text{其他} \end{cases}$
CD	$CD=\frac{100}{n_2} \sum_{u=1}^n d_i,$ $d_i=\begin{cases} 1, & (A_i-A_{i-1}) < 0 \text{ 并且 } (T_i-T_{i-1})(A_i-A_{i-1}) \geq 0 \\ 0, & \text{其他} \end{cases}$

注:A 和 T 分别表示真实值和预测值;n 是样本点总数目;n₁ 是上升趋势样本点的数目;n₂ 是下降趋势样本点的数目。

5 模型实证和结果解释

为使分析模型性能更贴近投资者的需求——判断未来股指的涨跌,本文在分析各模型的预测结果时专注于预测标准命中率(DS)。

本节对前向滚动 EMD 分解模型的预测结果与 ARIMA (autoregressive integrated moving average)模型、GARCH(generalized autoregressive conditional Heteroskedasticity)模型和 BP(back propagation)神经网络模型的预测结果进行比较。前向滚动 EMD 分解模型是一个混合组合预测模型,融合了前向滚动 EMD 分解与人工神经网络。EMD 算法被用于分解两个亚太股票指数的时间序列,经分解得到的 IMF 序列是平稳函数——这增强了神经网络的预测能力。ARIMA 模型的全称是差分自回归移动平均模型,是由 Box 和 Jenkins 于 20 世纪

70 年代初提出的一个著名时间序列预测方法,又称为 Box-Jenkins 模型、Box-Jenkins 法。ARIMA 模型的基本思想是:将预测对象随时间推移而形成的数据序列视为一个随机序列,用一定的数学模型来近似描述该序列。GARCH 模型的全称为广义自回归条件异方差模型。自从 Engle 于 1982 年提出利用 ARCH 模型分析时间序列的异方差性以后, Bollerslev 于 1986 年提出了 GARCH 模型。GARCH 模型是一个专门用于分析金融数据的回归模型,特别适用于分析和预测波动性——这样的分析对投资者做决策具有非常重要的指导作用,其意义很多时候超过了对数值本身的分析和预测。BP 神经网络预测模型是将股票指数时间序列不经 EMD 分解而直接输入神经网络训练后得到股票指

数预测值。这样做的目的是将 BP 神经网络预测模型与前向滚动 EMD 预测模型进行比较,分析使用 EMD 方法预处理预测变量能否提高预测性能,通过本文实证帮助读者进一步寻找更优的预测模型。

第 2 节已详细描述了前向滚动 EMD 分解技术的建模步骤。使用 EMD 方法分解数据,两个亚太股票指数的时间序列分别被分解为 7 个或 8 个独立的 IMF 分量和 1 个残差分量,如图 4 和图 5 所示。这些分解结果可提高模型的预测能力。然后,从上一步得到的分解预测变量,独立的 IMF 分量和残差分量被用于人工神经网络模型的构建。每个预测模型的性能评估标准见表 2。表 3 列出了各模型的预测性能度量结果。

表 3 各模型的预测效果

股票指数	模型	性能标准					
		MAD	MAPE	RMSE	DS(%)	CP(%)	CD(%)
澳大利亚指数	ARIMA 模型	132.8252	2.5632	177.5472	52.63	50.05	55.56
	GARCH 模型	103.9884	2.0496	134.5660	52.61	53.44	51.75
	BP 神经网络模型	207.7881	3.9473	239.1412	60.74	63.78	57.89
	前向滚动 EMD 分解模型	64.0529	1.2553	98.9438	65.86	64.62	67.23
沪深 300 指数	ARIMA 模型	90.1923	3.8817	108.5691	53.41	51.75	54.81
	GARCH 模型	107.1682	4.7027	137.1927	53.15	51.45	54.85
	BP 神经网络模型	133.2218	5.9219	167.3964	58.54	57.14	60.15
	前向滚动 EMD 分解模型	36.5433	1.5470	73.7625	64.26	65.22	63.43

为了验证所选择的 ARIMA 模型、GARCH 模型、BP 神经网络模型和前向滚动 EMD 分解模型的预测能力,本文使用两个亚太股票指数数据集——澳大利亚指数和沪深 300 指数。由表 3 可知,前向滚动 EMD 分解模型的 MAD、MAPE 和 RMSE 的值在所有模型中是最小的,即前向滚动 EMD 分解模型的实际值与预测值的偏差是最小的。此外,前向滚动 EMD 分解模型有更高的 DS、CP 和 CD,在分析沪深 300 指数走势时其命中率分别达到 64.26%、65.22%和 63.43%。DS、CP 和 CD 对股指移动趋势的预测显示出一致性。可以得出结论:前向滚动 EMD 分解模型具有更好的预测性能和命中率。此外,前向滚动 EMD 分解模型的预测结果与分解和集成的原则一致。时间序列分解可提高预测能力。以对沪深 300 指数的预测为例:与其他模型相比,前向滚动 EMD 分解模型比 ARIMA 模型、GARCH 模型和 BP 神经网络模型分别提高了 20.31%、20.90%和 9.77%。4 个模型对两个亚太股票指数的预测结果和性能比较见表 3 和表 4。可以看出,EMD 分解时间序列可提高神经网络的预测能力。

表 4 前向滚动 EMD 分解模型与其他模型相比的性能提高百分比

股票指数	模型	性能标准					
		MAD	MAPE	RMSE	DS	CP	CD
澳大利亚指数	ARIMA 模型	51.78	51.03	44.27	25.14	29.11	21.00
	GARCH 模型	38.41	38.75	26.47	25.19	20.92	30.06
	BP 神经网络模型	69.17	68.20	58.63	8.43	1.32	16.13
沪深 300 指数	ARIMA 模型	59.48	60.15	32.06	20.31	26.03	15.73
	GARCH 模型	65.90	67.10	46.23	20.90	26.76	15.64
	BP 神经网络模型	72.57	73.88	55.94	9.77	14.14	4.84

6 结语

如何找到一个有效的模型来解决非线性和非平稳的金融时间序列的预测问题受到人们越来越多的关注。本文引入前向滚动 EMD 分解计算。EMD 用于检测金融时间序列数据的移动趋势、提高人工神经网络的预测性能。通过实证比较不同模型对两个亚太股票指数的预测结果,可得前向滚动 EMD

分解模型的预测性能超过了 ARIMA 模型、GARCH 模型和 BP 神经网络模型。因此,本文提出的前向滚动 EMD 分解模型是一个可有效预测金融时间序列的工具,它解决了传统 EMD 分解技术长时延的问题。但是,滚动分解产生的 IMF 序列有很多,这使神经网络训练的数据过多、得到预测结果的时间过长。在后续研究中,笔者将考虑使用各种算法对 IMF 序列降维、压缩训练数据,进一步提高预测精度和缩短训练时间。

参考文献

- [1] DE GOOIJER J G, RAY B K, KRAGER H. Forecasting exchange rates using TSMARS[J]. Journal of International Money and Finance, 1998, 17(3): 513-534.
- [2] AWARTANI B M A, CORRADI V. Predicting the volatility of the S&P-500 stock index via GARCH models; the role of asymmetries [J]. International Journal of Forecasting, 2005, 21(1): 167-183.
- [3] PAI P F, LIN C S. A hybrid ARIMA and support vector machines model in stock price forecasting [J]. OMEGA-International Journal of Management Science, 2005, 33(6): 497-505.
- [4] TALEBI H, HOANG W, GAVRILOVA M L. Multi-scale foreign exchange rates ensemble for classification of trends in Forex market[J]. Procedia Computer Science, 2014, 29: 2065-2075.
- [5] PAN H P, HAIDAR I, KULKARNI S. Daily prediction of short-term trends of crude oil prices using neural networks exploiting multimarket dynamics[J]. Frontiers of Computer Science in China, 2009, 3(2): 177-191.
- [6] COTFAS L-A. A finite-dimensional quantum model for the stock market[J]. Physica A: Statistical Mechanics and its Applications, 2013, 392(2): 371-380.
- [7] IN F, KIM S. Multiscale hedge ratio between the Australian stock and futures markets: evidence from wavelet analysis [J]. Journal of Multinational Financial Management, 2006, 16(4): 411-423.
- [8] Yu Lean, Wang Shouyang, Lai Kin Keung. Forecasting crude oil price with an EMD-based neural network ensemble learning paradigm [J]. Energy Economics, 2008, 30(5): 2623-2635.
- [9] Zhang Xun, Yu Lean, Wang Shouyang, et al. Estimating the impact of extreme events on crude oil price: an EMD-based event analysis method [J]. Energy Economics, 2009, 31(5): 768-778.
- [10] Lin Chiun-Sin, Chiu Sheng-Hsiung, Lin Tzu-Yu. Empirical mode decomposition-based least squares support vector regression for foreign exchange rate forecasting[J]. Economic Modelling, 2012, 29(6): 2583-2590.
- [11] Cheng Ching-Hsue, Wei Liang-Ying. A novel time-series model based on empirical mode decomposition for forecasting TAIEX[J]. Economic Modelling, 2014, 36: 136-141.
- [12] Li Qian, Bao Liang. Enhanced index tracking with multiple time-scale analysis [J]. Economic Modelling, 2014, 39: 282-292.
- [13] IVANOV S I, JONES F J, ZAIMA J K. Analysis of DJIA, S&P 500, S&P 400, NASDAQ 100 and Russell 2000 ETFs and their influence on price discovery [J]. Global Finance Journal, 2013, 24: 171-187.
- [14] MENSI W, BELJID M, BOUBAKER A, et al. Correlations and volatility spillovers across commodity and stock markets: linking energies, food and gold [J]. Economic Modelling, 2013, 32: 15-22.
- [15] CARAIANI P. Characterizing emerging European stock markets through complex networks: From local properties to self-similar characteristics [J]. Physica A, 2012, 391: 3629-3637.
- [16] Wu Ming-Chya. Phase correlation of foreign exchange time series [J]. Physica A, 2007, 375: 633-642.
- [17] 熊志斌. ARIMA 融合神经网络的人民币汇率预测模型研究 [J]. 数量经济技术经济研究, 2011(6): 64-76.
- [18] 黄海南, 钟伟. GARCH 类模型波动率预测评价 [J]. 中国管理科学, 2007, 15(6): 13-19.
- [19] 李成刚, 田益祥, 何继锐. AC 算法的 EMD 分解 GMDH 组合的预测模型及应用 [J]. 系统工程, 2012, 21(1): 105-110.
- [20] 杨云飞, 鲍玉昆, 胡忠义, 等. 基于 EMD 和 SVMs 的原油价格预测方法 [J]. 管理学报, 2010, 7(12): 1884-1889.
- [21] KROGH A, VEDELSBY J. Neural network ensembles, cross validation and active learning [J]. Neural Computing & Application, 1995, 25: 231-238.
- [22] HUANG N E, SHEN Z, LONG S R, et al. The empirical mode decomposition and the Hilbert spectrum for nonlinear and non-stationary time series analysis [C]. Proceedings of the Royal Society A: Mathematical, Physical and Engineering Sciences, 1998.
- [23] WU Z, HUANG N E. A study of the characteristics of white noise using the empirical mode decomposition method [C]. Proceeding of the Royal Society. London 460A, 2004.
- [24] LU C J, LEE T S, CHIU C C. Financial time series forecasting using independent component analysis and support vector machine [J]. Decision Support Systems, 2009, 47(2): 115-125.
- [25] TAY F E H, CAO L. Application of support vector machines in financial time series forecasting [J]. Omega, 2001, 29(4): 309-317.

Prediction Model Based on Forward Rolling EMD

Zhang Chengzhao¹, Pan Heping^{2,3}

(1. School of Management and Economics, University of Electronic Science and Technology, Chengdu 611731, China;

2. Chongqing Institute of Finance, Chongqing 400067, China; 3. School of Economics, Sichuan University, Chengdu 610064, China)

Abstract: A new combined forecasting model is built in this paper by using empirical mode decomposition(EMD), artificial neural network (ANN) and time series methods based on the idea of decomposition-reconstruction-integration. During the process of building this model, a new idea to decompose the stock index sequence by forward rolling EMD method is proposed. After decomposition, the intrinsic mode function(IMF) components are input into neural network to implement the combination forecast. Then this model is used to analyze the fluctuation characteristics and the trend of Chinese Stock Index(CSI300) and Australian stock index. Empirical analysis result shows that, comparing with ARIMA model, GARCH model and BP neural network model, forward rolling EMD model obtains better forecasting result.

Key words: EMD; ANN; forward rolling decomposition; IMF

(上接第 4 页)

- [10] LÜTHJE C, HERSTATT C. The lead user method: an outline of empirical findings and issues for future research[J]. R&D Management, 2004, 34(5): 553-568.
- [11] OGAWA S. Does sticky information affect the locus of innovation? Evidence from the Japanese convenience-store industry[J]. Research Policy, 1998, 26(7/8): 777-790.
- [12] SÁNCHEZ-GONZÁLEZ G, GONZÁLEZ-ÁLVAREZ N, MARIANO N. Sticky information and heterogeneous needs as determining factors of R&D cooperation with customers[J]. Research Policy, 2009, 38(10): 1590-1603.
- [13] SHAH S K. Sources and patterns of innovation in a consumer product field: innovation in sporting equipment (Working Paper 4105) [R]. Cambridge, MA: Sloan School of Management, MIT, 2000.
- [14] HERTEL G, NIEDNER S, HERMANN S. Motivation of software developers in open source projects: An Internet-based survey of contributors to the Linux Kernel[J]. Research Policy, 2003, 32: 1159-1177.
- [15] IVES B, OLSON M H. User involvement and MIS success; a review of research [J]. Management Science, 1984, 30(5): 585-603.
- [16] KAULIO M A. Customer, consumer and user involvement in product development: a framework and a review of selected methods [J]. Total Quality Management, 1998, 9(1): 141-149.
- [17] 董艳, 张大亮, 徐伟青. 用户创新的条件和范式研究[J]. 浙江大学学报: 人文社会科学版, 2009, 39(4): 43-44.
- [18] 吴伟. 新产品开发中用户参与的路径和策略研究[M]. 沈阳: 东北大学出版社, 2010.
- [19] 刘少杰. 当代国际社会学理论[M]. 北京: 中国人民大学出版社, 2009.
- [20] 罗纳德·伯特. 结构洞: 竞争的社会结构[M]. 上海: 世纪出版集团, 2008.
- [21] 杨寿仁, 单秀云, 于慧云. 组织理论与案例: 个案、衡量与产业应用[M]. 台北: 双叶书廊有限公司, 2009.
- [22] KNICHERBOCKER F T. Oligopolistic reaction and multinational enterprise[J]. Thunderbird International Business Review, 1973, 15(2): 7-9.
- [23] 乔纳森·H·特纳. 社会学理论的结构[M]. 北京: 华夏出版社, 2006.

Research on Cause of User Dominating Innovation Based on Structural Hole Theory

Su Nan¹, Wu Guisheng²

(1. Chinese Academy of Science and Technology for Development, Beijing 100038, China;

2. Research Center for Technological Innovation, Tsinghua University, Beijing 100084, China)

Abstract: This paper regards user dominating innovation as a inter-organization relationship, and analyzes its causes with the structural hole theory. It considers that user dominating innovation fills original structural hole, at the same time users connect the structural holes which have been occupied by foreign manufacturers and get common benefits together with domestic manufacturers.

Key words: user innovation; user dominating innovation; co-innovation; structural hole theory; equipment manufacturing industry